



CS2568/หมายเลขกลุ่ม
เค้าโครงโครงงานคอมพิวเตอร์

ระบบสืบค้นและระบุช่วงเวลาในวิดีโอด้วยภาษาธรรมชาติแบบไฮบริดหลายมิติ

(Pure-Visual Video Moment Retrieval and Temporal Localization
System)

โดย

รหัสนักศึกษา นาย/นางสาว

รหัสนักศึกษา นาย/นางสาว

อาจารย์ที่ปรึกษา ผู้ช่วยศาสตราจารย์ ดร. สิลดา อินทรโสธรรัตน์

รายงานนี้เป็นส่วนหนึ่งของการศึกษาวิชา CP353761 สัมมนาทางวิทยาการคอมพิวเตอร์

ภาคเรียนที่ 1 ปีการศึกษา 2568

สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์

มหาวิทยาลัยขอนแก่น

(เดือน กันยายน พ.ศ. 2568)

การเสนอเค้าโครงโครงการคอมพิวเตอร์

สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น

ชื่อ นาย / นางสาว รหัสประจำตัว

Mr. / Miss

นาย / นางสาว รหัสประจำตัว

Mr. / Miss

นักศึกษาระดับปริญญาตรี หลักสูตรวิทยาการคอมพิวเตอร์

อาจารย์ที่ปรึกษาโครงงาน ผู้ช่วยศาสตราจารย์ ดร. สิลดา อินทรโสธรจันทร์

Project Advisor Asst. Prof. Dr. Silada Indrasothornsunt

1. ชื่อหัวข้อโครงงาน

ภาษาไทย: ระบบสืบค้นและระบุช่วงเวลาในวิดีโอด้วยภาษาธรรมชาติแบบไฮบริดหลายมิติ

ภาษาอังกฤษ: Pure-Visual Video Moment Retrieval and Temporal Localization
System

2. หลักการและเหตุผล

ในยุคสารสนเทศปัจจุบัน

ปริมาณข้อมูลสื่อวิดีโอความยาวสูงเติบโตขึ้นอย่างก้าวกระโดดในทุกภาคส่วน ทั้งในด้านการศึกษา

เช่น วิดีโอบันทึกการเรียนการสอนและการนำเสนอทางวิชาการ ด้านการทำงาน เช่น

วิดีโอบันทึกการประชุม ตลอดจนด้านความปลอดภัยและนิติวิทยาศาสตร์ เช่น

footage จากกล้องวงจรปิดและกล้องติดหน้ารถยนต์ อย่างไรก็ตาม

ปัญหาข้อจำกัดสำคัญที่ผู้ใช้งานต้องเผชิญคือการค้นหาและระบุตำแหน่งช่วงเวลาที่เกิดเหตุ

การณ์เฉพาะเจาะจง

ซึ่งผู้ใช้งานจำเป็นต้องเสียเวลาเปิดรับชมหรือเลื่อนแถบเวลายาวนานหลายสิบนาทีถึงหลายชั่วโมง

เพื่อค้นหาเหตุการณ์สั้น ๆ เพียงไม่กี่วินาที

ระบบสืบค้นวิดีโอแบบดั้งเดิมส่วนใหญ่ยังคงพึ่งพาเฉพาะข้อมูลกำกับภายนอก เช่น ชื่อไฟล์ แท็ก หรือคำอธิบายภาพรวม ซึ่งไม่สามารถเข้าถึงเนื้อหาเชิงลึกในระดับช่วงเวลา และไม่สามารถเข้าใจคำค้นหาภาษาธรรมชาติที่ซับซ้อนได้ เช่น "ช่วงที่อาจารย์เริ่มอธิบายสไลด์กราฟแท่งเปรียบเทียบผลลัพธ์" หรือ "ตอนที่มีคนสวมเสื้อสีแดงเดินเข้ามาหยิบกระเป๋าใบโตๆ" หรือ "ฉากที่รถจักรยานยนต์เลี้ยวตัดหน้ากะทันหันก่อนถึงทางแยก"

การสืบค้นเหตุการณ์เหล่านี้จำเป็นต้องอาศัยความเข้าใจร่วมกันระหว่างภาพนิ่ง การกระทำต่อเนื่อง และความสัมพันธ์เชิงเวลาอย่างลึกซึ้ง

นอกจากนี้บริการสืบค้นวิดีโอบนคลาวด์ในปัจจุบันส่วนใหญ่มีค่าใช้จ่ายตามปริมาณการใช้งาน และต้องส่งข้อมูลวิดีโอออกไปประมวลผลภายนอกองค์กร ซึ่งอาจก่อให้เกิดความเสี่ยงด้านความเป็นส่วนตัวของข้อมูลที่มีความอ่อนไหว เช่น วิดีโอการประชุมภายในหรือฟุตเทจจากกล้องรักษาความปลอดภัย

ในช่วงปี ค.ศ. 2024–2026

วงการปัญญาประดิษฐ์ได้พัฒนาแบบจำลองพื้นฐานด้านภาษาและภาพที่ก้าวหน้าอย่างมาก ได้แก่ SigLIP 2 พัฒนาโดย Google DeepMind ซึ่งรองรับสถาปัตยกรรม NaFlex ช่วยรักษารายละเอียดภาพและตำแหน่งเชิงพื้นที่ในวิดีโออัตราส่วน 16:9 ได้อย่างสมบูรณ์โดยไม่ต้องตัดขอบหรือบิดเบือนภาพ ควบคู่กับแบบจำลองภาษาภาพขนาดใหญ่ เช่น Qwen2.5-VL และ CapRL-Qwen3VL-4B ที่สามารถสร้างคำบรรยายจากภาพแบบละเอียดและตรวจสอบความถูกต้องของเหตุการณ์ได้ ตลอดจนฐานข้อมูลเวกเตอร์ประสิทธิภาพสูงอย่าง LanceDB ที่ทำงานบนสถาปัตยกรรม Apache Arrow และรองรับการค้นหาแบบไฮบริดทั้งเวกเตอร์ภาพและการค้นหาข้อความเต็มรูปแบบด้วย BM25

โครงการนี้จึงนำเสนอการวิจัยและพัฒนาระบบสืบค้นและระบุตำแหน่งช่วงเวลาในวิดีโอด้วยภาษาธรรมชาติแบบไฮบริดหลายมิติ ที่ทำงานบนเครื่องประมวลผลส่วนบุคคลทั้งหมดโดยไม่ต้องส่งข้อมูลออกสู่คลาวด์ภายนอก

ช่วยรักษาความเป็นส่วนตัวของข้อมูลและประหยัดต้นทุนได้อย่างเด็ดขาด

โดยผสมการดึงข้อมูลเวกเตอร์ภาพและคำบรรยายจากด้วย Reciprocal Rank Fusion (RRF)

ร่วมกับการเกลี่ยสัญญาณเวลา 1D Gaussian Convolution

และการสกัดขอบเขตเวลาอย่างแม่นยำด้วย Soft-NMS และ Platt Calibration

3. วัตถุประสงค์ของโครงการ

3.1 เพื่อออกแบบและพัฒนาระบบสกัดข้อมูลวิดีโอเร่งความเร็วด้วยฮาร์ดแวร์ โดยใช้ Decord สำหรับถอดรหัสวิดีโอบน GPU ควบคู่กับการตัดแบ่งฉากด้วย PySceneDetect เพื่อลดปริมาณเฟรมซ้ำซ้อน

3.2 เพื่อประยุกต์ใช้แบบจำลองภาษาภาพบนเครื่องประมวลผลส่วนบุคคล ได้แก่ SigLIP 2 NaFlex สำหรับการสกัดเวกเตอร์ตัวแทนของเฟรมภาพและคำค้นหา และ CapRL-Qwen3VL-4B สำหรับสร้างคำบรรยายฉากและตรวจสอบความถูกต้องเชิงลึก

3.3 เพื่อพัฒนาฐานข้อมูลเวกเตอร์และระบบสืบค้นประสิทธิภาพสูง โดยใช้ LanceDB บนโครงสร้าง Apache Arrow ร่วมกับดัชนี Disk-based IVF-PQ และการค้นหาข้อความเต็มรูปแบบด้วย Tantivy BM25

3.4 เพื่อพัฒนาระบบคำนวณและระบุขอบเขตช่วงเวลาเหตุการณ์ที่ผสมผสานคะแนนหลายมิติด้วย Reciprocal Rank Fusion, การเกลี่ยสัญญาณเวลา 1D Gaussian Convolution, การสกัดขอบเขตช่วงเวลาด้วย Soft-NMS, และการปรับเทียบความเชื่อมั่นด้วย Platt Calibration

3.5 เพื่อพัฒนาเว็บแอปพลิเคชันส่วนต่อประสานผู้ใช้แบบโต้ตอบ ด้วย Next.js และ FastAPI ที่มีแถบแสดงความหนาแน่นของความเกี่ยวข้องแบบ 1-Hz Relevance Heatmap และระบบเล่นวิดีโอแบบเลื่อนไปยังช่วงเวลาเป้าหมายอัตโนมัติ

3.6 เพื่อประเมินประสิทธิภาพของระบบอย่างครอบคลุม ทั้งบนชุดข้อมูลมาตรฐานสากล QVHighlights และ Charades-STA, ชุดข้อมูลวิดีโอสถานการณ์จริง 30 ชั่วโมง, และการทดสอบกับกลุ่มผู้ใช้งานจริง

4. ทฤษฎีและผลงานวิจัยที่เกี่ยวข้อง

การศึกษาทฤษฎีและงานวิจัยที่เกี่ยวข้องเพื่อการพัฒนาโครงงานฉบับนี้ ได้ทำการรวบรวม วิเคราะห์ และสังเคราะห์องค์ความรู้อย่างเป็นระบบ โดยครอบคลุมทั้งวรรณกรรมวิจัยสำคัญตามกรอบการคิดวิเคราะห์ 5W1H (Who, What, Where, When, Why, How), ทฤษฎีและหลักการทางคณิตศาสตร์ที่เกี่ยวข้อง, และตารางสังเคราะห์วรรณกรรม (Synthesis Matrix) ดังมีรายละเอียดต่อไปนี้:

4.1 งานวิจัยที่เกี่ยวข้อง (การสังเคราะห์วรรณกรรมตามกรอบ 5W1H)

จากการทบทวนวรรณกรรมวิจัยสำคัญจำนวน 12 งานวิจัย สามารถจำแนกออกเป็น 4 กลุ่มหลักได้ดังนี้:

4.1.1 งานวิจัยด้านการโมเดลความสัมพันธ์เชิงเวลาและการตรวจจับด้วย

Transformer และ DETR

1) โครงข่าย 2D-TAN (Zhang et al., 2020): นำเสนอโครงข่าย 2D Temporal Adjacent Networks เพื่อแก้ปัญหา 1D Sliding Window

ที่ขาดการมองเห็นความสัมพันธ์ของช่วงเวลาเหตุการณ์ซ้อนทับ โดยแปลงวิดีโอเป็น 2D Temporal Feature Map ตามแกนเริ่มต้นและแกนสิ้นสุด แล้วใช้ 2D Convolution ดึงบริบทเชิงเวลาก่อนจับคู่กับคำค้นหา

2) ชุดข้อมูล QVHighlights และแบบจำลอง Moment-DETR (Lei et al., 2021):

เสนอเกณฑ์การประเมินช่วงเวลาแบบ Fine-grained Saliency Score รายวินาที โดยใช้โครงสร้าง DETECTION TRANSFORMER

ทำนายพิกัดช่วงเวลาระหว่างจุดเริ่มต้นถึงจุดสิ้นสุดและคะแนนความโดดเด่นตลอดคลิปไปพร้อมกัน

3) แบบจำลอง QD-DETR (Moon et al., 2023): พัฒนา Query-Dependent DETR

เพื่อแก้ปัญหาคำค้นหาที่คลุมเครือแบบไม่ขึ้นกับคำค้นหา โดยใช้ Cross-Attention

ปรับแต่งการเข้ารหัสวิดีโอตั้งแต่ขั้นแรก และใช้ Negative Pairs

กีดคะแนนจากที่ไม่เกี่ยวข้องลง

4) กรอบการทำงาน UniVTG (Lin et al., 2023): รวมศูนย์ภารกิจการสับคั่นช่วงเวลา การตรวจจับจุดเด่น และการสรุปวิดีโอเข้าด้วยกันบนแกนหลัก Transformer เดียวกัน รองรับการถ่ายโอนความรู้ข้ามภารกิจได้อย่างมีประสิทธิภาพ

5) สถาปัตยกรรม ActionFormer (Zhang et al., 2022):

ออกแบบการตรวจจับเหตุการณ์แบบไม่ใช้ Anchor โดยใช้ Multi-scale 1D Temporal Convolution ผสานกับ Self-Attention

เพื่อทำนายขอบเขตเวลาทั้งกิจกรรมสั้นและยาวได้อย่างยืดหยุ่น

4.1.2 งานวิจัยด้านแบบจำลองภาษาภาพและวิดีโอ

6) แบบจำลอง SigLIP 2 (Google DeepMind, 2025): แก้ปัญหาภาพวิดีโอ 16:9

ถูกบิดเบือนในแบบจำลองยุคแรกด้วยนวัตกรรม NaFlex

ที่ประมวลผลภาพตามอัตราส่วนจริง พร้อมใช้ Pairwise Sigmoid Loss, Masked Prediction, และ Self-Distillation ทำให้เข้าใจตำแหน่งเชิงพื้นที่ได้เหนือกว่าเดิมอย่างมาก

7) แบบจำลอง Qwen2.5-VL และ CapRL-Qwen3VL-4B (2024–2025):

แบบจำลองภาษาภาพขนาดใหญ่สำหรับสร้างคำบรรยายจากภาพแบบละเอียด

และทำหน้าที่ตรวจสอบเหตุการณ์เชิงลึก

โดยส่งเฟรมภาพจริงพร้อมพิกัดเวลาเข้าไปให้แบบจำลองประเมินความสอดคล้อง

8) แบบจำลอง TimeChat (Ren et al., 2024):

แก้ปัญหาการขาดความเข้าใจมิติเวลาของโมเดลภาษาขนาดใหญ่

โดยใช้ตัวเข้ารหัสเฟรมที่คำนึงถึงเวลาควบคู่กับ Time Binding Tokens

เพื่อผูกมิติเวลาเข้ากับคำตอบของแบบจำลอง

9) แบบจำลอง Video-LLaVA (Lin et al., 2024):

ผสานบริบทการแทนข้อมูลของภาพนิ่งและวิดีโอให้อยู่ในระนาบเดียวกัน

ช่วยให้แบบจำลองเข้าใจความสัมพันธ์เชิงบริบทได้สมบูรณ์ยิ่งขึ้น

4.1.3

งานวิจัยด้านการตรวจสอบลำดับการกระทำเชิงภาพและการตรวจจับรอยต่อฉาก

10) สถาปัตยกรรม Two-Stage Retrieval:

แยกการค้นหาผู้สมัครรอบแรกความเร็วสูงด้วยเวกเตอร์และ BM25

ออกจากการตรวจสอบเชิงลึกด้วยแบบจำลองภาษาภาพ

เพื่อควบคุมเวลาและทรัพยากรให้อยู่ในเกณฑ์ที่เหมาะสม

11) แบบจำลอง ImageBind (Girdhar et al., 2023):

พิสูจน์แนวความคิดการใช้ภาพเป็นแกนกลางในการเชื่อมโยงข้อมูลหลายรูปแบบในบริภูมิร่วมเดียวกัน ซึ่งเป็นรากฐานสำคัญของการสืบค้นแบบไฮบริด

12) สถาปัตยกรรม TransNet V2 (Souček & Lokoč, 2020): โครงข่าย 3D CNN

ตรวจจับรอยต่อฉากด้วยความเร็วสูงกว่า 500 เฟรมต่อวินาที

เพื่อตัดแบ่งวิดีโอและลดปริมาณเฟรมซ้ำซ้อนลงกว่าร้อยละ 75

ตารางที่ 4.1 สรุปการวิเคราะห์งานวิจัยที่เกี่ยวข้องด้วยกรอบ 5W1H

งานวิจัย	ผู้พัฒนา	ปี	สาระสำคัญที่พัฒนา	ปัญหาที่แก้ไข	วิธีการหลัก
2D-TAN	Zhang et al.	2020	2D Temporal Adjacent Networks	1D Window ขาดความสัมพันธ์ข้ามเวลา	2D Convolution บน Feature Map
Moment-DETR	Lei et al.	2021	Joint Moment & Saliency Grounding	ขาดเกณฑ์ประเมินคะแนนระดับวินาที	Transformer Direct Set Prediction
QD-DETR	Moon et al.	2023	Query-Dependent Video DETR	ฉากที่ไม่เกี่ยวข้องได้คะแนนสูงเกินจริง	Query Cross-Attention & Negative Loss
UniVTG	Lin et al.	2023	Unified Temporal Grounding	การแยกพัฒนาแต่ละภารกิจย่อยในอดีต	Unified Transformer Backbone

งานวิจัย	ผู้พัฒนา	ปี	สาระสำคัญที่พัฒนา	ปัญหาที่แก้ไข	วิธีการหลัก
ActionFormer	Zhang et al.	2022	Anchor-free 1D Temporal Grounding	กรอบเวลาแบบ Anchor ขาดความยืดหยุ่น	Multi-scale 1D Temporal Pyramid
SigLIP 2	DeepMind	2025	NaFlex Vision-Language Model	ภาพ 16:9 ถูกยืดและสูญเสียมิติพื้นที่	NaFlex Dynamic Res & Sigmoid Loss
Qwen2.5-VL	Qwen Team	2024	Dense Caption + Verification	VLM ทัวไปประมวลผลช้าเกินไป	Sequential Top-3 Candidates Verify
TimeChat	Ren et al.	2024	Time-Sensitive Video-LLM	LLM ขาดความเข้าใจลำดับมิติเวลา	Time Binding Tokens & Frame Encoder
Video-LLaVA	Lin et al.	2024	Unified Image-Video Representation	การแยก Representation ภาพและวิดีโอ	Joint Representation Alignment Layer
Pure-Visual	โครงการนี้	2026	Dual-Channel Hybrid Retrieval	การพึ่งพาเสียงหรือ Cloud API ราคาแพง	Frame SigLIP 2 + Scene BM25 + RRF
ImageBind	Girdhar et al.	2023	One Embedding for 6 Modalities	การผสมผสานหลายมิติขาดข้อมูลจับคู่	Image-Centric Joint Binding Space
TransNet V2	SouČek et al.	2020	Fast Shot Boundary Detection	การประมวลผลทุกเฟรมทำให้ระบบช้า	Dilated 3D Convolutional Network

4.2 ทฤษฎีและหลักการทางคณิตศาสตร์ที่เกี่ยวข้อง

4.2.1 ทฤษฎีปริภูมิแฝงร่วมระหว่างภาพและภาษาและสถาปัตยกรรม NaFlex:

แบบจำลองแปลงเฟรมภาพ f_t และคำค้นหาข้อความ Q ให้อยู่ในปริภูมิเวกเตอร์เดียวกันขนาด $d = 768$ มิติ โดยคำนวณความคล้ายคลึงด้วย Cosine Similarity:

$$\text{Cosine_Similarity}(f_t, Q) = (v_t \cdot u_q) / (\|v_t\| \times \|u_q\|)$$

โดยที่ v_t คือเวกเตอร์แทนภาพจาก Vision Encoder และ u_q

คือเวกเตอร์แทนข้อความจาก Text Encoder กลไก NaFlex ช่วยให้โมเดลรองรับภาพอัตราส่วน 16:9 ได้โดยตรงโดยไม่สูญเสียความละเอียดเชิงพื้นที่

4.2.2 ทฤษฎีฟังก์ชันการสูญเสียแบบจับคู่ Pairwise Sigmoid Loss: SigLIP 2

ใช้ฟังก์ชันการสูญเสียแบบ Sigmoid แทน Softmax ดั้งเดิม ช่วยลดการพึ่งพา Global Batch Size และทำให้เวกเตอร์มีความเสถียรสูงขึ้น:

$$L_{\text{SigLIP}} = - \sum_{i=1}^N \sum_{j=1}^N [y_{ij} \cdot \log \sigma(t \cdot u_i \cdot v_j + b) + (1 - y_{ij}) \cdot \log(1 - \sigma(t \cdot u_i \cdot v_j + b))]$$

โดย $y_{ij} = 1$ สำหรับคู่ที่ตรงกัน และ $y_{ij} = 0$ สำหรับคู่ตรงข้าม, σ คือ Sigmoid

Activation, t คือ Temperature, และ b คือ Bias ที่เรียนรู้ได้

4.2.3 ทฤษฎีการรวมผลลัพธ์ด้วย Reciprocal Rank Fusion (RRF):

ผสานผลลัพธ์จากสายเวกเตอร์ภาพและสายคำบรรยายจากที่มีมาตรวัดต่างกันโดยไม่ต้องปรับสเกลคะแนน:

$$\text{RRF}(d) = \sum_{m \in \{\text{Visual}, \text{Caption}\}} [w_m / (k + r_m(d))]$$

โดย $r_m(d)$ คืออันดับของข้อมูลในแต่ละช่องทาง กำหนด $k = 60$

เพื่อป้องกันอันดับแรกมีน้ำหนักสูงเกินไป และ w_m คือค่าน้ำหนัก (Visual = 0.80, Caption = 0.20)

4.2.4 ทฤษฎีการสร้างช่วงเวลาผู้สมัครและการเกลี่ยสัญญาณเวลา 1D Gaussian

Convolution: สร้างช่วงเวลาผู้สมัครที่มีความยาวต่าง ๆ ตั้งแต่ 2 ถึง 32 วินาที โดยนำคะแนน $S(t)$

มาผ่านตัวกรอง Gaussian Filter: $S_{\text{smooth}}(t) = S(t) * G_{\sigma}$ เพื่อลดสัญญาณรบกวน

จากนั้นขยายขอบเขตจากจุดสูงสุดเฉพาะที่คะแนนลดต่ำกว่าร้อยละ 60 ของจุดสูงสุด และใช้ Soft-NMS เพื่อตัดช่วงซ้ำซ้อน

4.2.5 ทฤษฎีการปรับเทียบความเชื่อมั่นด้วย Platt Calibration: ใช้ฟังก์ชัน Logistic Sigmoid แปลงคะแนนดิบเป็นค่าความน่าจะเป็นเชิงสถิติ $P(Y=1|S) = 1 / (1 + \exp(A \cdot S + B))$ เพื่อตัดช่วงเวลาที่ไม่เกี่ยวข้องออกอย่างแม่นยำ

4.2.6 ทฤษฎีการจัดเก็บและสร้างดัชนีเวกเตอร์แบบ Disk-based IVF-PQ: LanceDB ใช้สถาปัตยกรรม Columnar บน Apache Arrow ร่วมกับดัชนี Inverted File with Product Quantization (IVF-PQ) แบ่งเวกเตอร์ 768 มิติออกเป็นคลัสเตอร์และบีบอัดแต่ละส่วน ช่วยประหยัดหน่วยความจำได้ 8–16 เท่า และสืบค้นได้เร็วกว่า 5 มิลลิวินาที

ตารางที่ 4.2 ตารางสังเคราะห์วรรณกรรม (Synthesis Matrix)

เปรียบเทียบสถาปัตยกรรมและมิติข้อมูล

แนวทาง / งานวิจัย	มิติข้อมูล	สถาปัตยกรรมหลัก	จุดเด่นสำคัญ	ข้อจำกัดและช่องว่างวิจัย
Proposal-based (2D-TAN)	Visual Only (2D CNN)	Sliding Window & 2D Temporal Feature Map	เข้าใจความสัมพันธ์ของช่วงเวลาซ้อนทับได้ดี	ไม่รองรับ Open-Vocabulary คำนวณข้ามวิดีโอยาว
DETR-based (Moment-DETR)	Visual + Text	Transformer Encoder-Decoder Set Prediction	ทำนายช่วงเวลาและ Highlight Score พร้อมกัน	ต้อง Fine-tune บนชุดข้อมูลปิด กิน VRAM สูง
Unified Grounding (UniVTG)	Visual + Text	Multi-scale 1D Temporal Convolution	สกัดเหตุการณ์สั้นและยาวได้อย่างยืดหยุ่น	ยังขาดระบบดัชนีเวกเตอร์ที่รองรับคลังวิดีโอใหญ่
TimeChat (Video-LLM)	Visual + Text	Large Language Model & Time Tokens	เข้าใจการกระทำซับซ้อนและตอบคำถามเหตุผลได้	กินทรัพยากรสูง ประมวลผลช้า เหมาะกับ Re-rank

แนวทาง / งานวิจัย	มิติข้อมูล	สถาปัตยกรรมหลัก	จุดเด่นสำคัญ	ข้อจำกัดและช่องว่างวิจัย
Two-Stage (SeViLA)	Multi-modal Binding	Localizer-Filter + Answerer VLM	ประหยัด Token ในงาน Video QA	ไม่มี Vector DB ผังตัวสำหรับค้นหาทันที
Proposed Pure-Visual (โครงงานนี้)	Visual Vector + Dense Caption	SigLIP 2 NaFlex + Qwen + LanceDB	รักษา Aspect Ratio, รองรับหลาย Moments, Local VRAM $\leq 12\text{GB}$	ต้องทำดัชนีล่วงหน้า และขึ้นกับความคมชัดของภาพ

4.3 บทวิเคราะห์สังเคราะห์วรรณกรรม: จากการทบทวนวรรณกรรมพบประเด็นสำคัญ 3 ประการ ได้แก่ (1) การผสมผสานสัญญาณสองช่องทาง โดยเวกเตอร์ภาพระดับเฟรมช่วยครอบคลุมเส้นเวลา ส่วนคำบรรยายจากช่วยจับบริบทการกระทำต่อเนื่อง (2) ความสำคัญของอัตราส่วนภาพ ซึ่งสถาปัตยกรรม NaFlex ช่วยแก้ปัญหาภาพบิดเบือนในวิดีโอ 16:9 ได้อย่างสมบูรณ์ และ (3) ความสมดุลด้านความเร็ว โดยการออกแบบระบบสองระยะที่แยกการค้นหารอบแรกระดับมิลลิวินาทีออกจากการตรวจทานเชิงลึก ช่วยให้ระบบตอบสนองผู้ใช้ได้ทันทีโดยไม่ติดขัด

5. วิธีดำเนินการวิจัย

โครงงานนี้ได้กำหนดขั้นตอนและระเบียบวิธีดำเนินการวิจัยออกเป็น 8 ขั้นตอนหลัก เพื่อให้การพัฒนาระบบเป็นไปอย่างมีประสิทธิภาพและบรรลุวัตถุประสงค์ที่ตั้งไว้ ดังนี้:

5.1 การศึกษาค้นคว้าทฤษฎีและเทคโนโลยีที่เกี่ยวข้อง

ศึกษาทฤษฎีด้านแบบจำลองภาษาภาพพื้นฐาน, การสืบค้นช่วงเวลาในวิดีโอด้วยภาษาธรรมชาติ, ฐานข้อมูลเวกเตอร์, และการระบุขอบเขตช่วงเวลาเชิงเวลา ตลอดจนศึกษาสถาปัตยกรรม SigLIP 2, Qwen2.5-VL, Decord, LanceDB, และ Next.js

5.2 การออกแบบสถาปัตยกรรมระบบโดยรวม

ออกแบบสถาปัตยกรรมแบบสองช่องทางคู่ขนาน

ประกอบด้วยระบบนำเข้าและสกัดข้อมูลวิดีโอ, ขั้นตอนการจัดเก็บข้อมูลบน LanceDB, กลไกสืบค้นที่ผสมผสาน RRF ร่วมกับ Gaussian Smoothing, และส่วนต่อประสานผู้ใช้

5.3 การออกแบบโครงสร้างฐานข้อมูลเวกเตอร์ LanceDB

ออกแบบโครงสร้างตารางข้อมูลบน Apache Arrow ประกอบด้วยตาราง videos สำหรับจัดเก็บข้อมูลไฟล์, ตาราง video_frames_v2 สำหรับจัดเก็บเวกเตอร์ 768 มิติของเฟรมภาพ, ตาราง scenes_v2 สำหรับจัดเก็บคำบรรยายฉาก, และตาราง index_metadata สำหรับตรวจสอบความเข้ากันได้ของแบบจำลอง

5.4 การพัฒนาระบบนำเข้าและประมวลผลวิดีโอแบบก้าวหน้า

พัฒนาโมดูลถอดรหัสวิดีโอด้วย Decord ผ่านการเร่งความเร็วบน GPU, โมดูลตรวจจับรอยต่อฉากด้วย PySceneDetect, และโมดูลสกัดเวกเตอร์ SigLIP 2 ในระยะแรกเพื่อให้เริ่มค้นหาได้ทันที
ก่อนส่งฉากไปสร้างคำบรรยายด้วยแบบจำลองภาษาภาพในเบื้องหลัง

5.5 การพัฒนาระบบสืบค้นและระบุตำแหน่งเวลาแบบไฮบริด

พัฒนาระบบค้นหาคู่ขนานระหว่างการค้นหาเวกเตอร์ภาพและการค้นหาข้อความเต็มรูปแบบด้วย BM25 บนคำบรรยายฉาก ผสานคะแนนด้วย RRF, เกลี่ยสัญญาณด้วย 1D Gaussian Convolution, สกัดช่วงเวลาระหว่างจุดเริ่มต้นถึงจุดสิ้นสุดด้วย Soft-NMS, และปรับเทียบความเชื่อมั่นด้วย Platt Calibration

5.6 การพัฒนาเว็บแอปพลิเคชันส่วนต่อประสานผู้ใช้

พัฒนาเว็บแอปพลิเคชันด้วย Next.js และ FastAPI รองรับการอัปโหลดวิดีโอ, แถบแสดงความหนาแน่นของความเกี่ยวข้องแบบ 1-Hz Relevance Heatmap, ระบบเล่นวิดีโอแบบเลื่อนไปยังช่วงเวลาเป้าหมายอัตโนมัติ, และแผงตรวจสอบการใช้งานหน่วยความจำ VRAM บน GPU

5.7 การทดลองและประเมินประสิทธิภาพของระบบ

ทดสอบประสิทธิภาพบนชุดข้อมูลมาตรฐาน QVHighlights และ Charades-STA, ทดสอบบนวิดีโอสถานการณ์จริง 30 ชั่วโมง, ทำการทดลองแยกส่วนประกอบ 5 รูปแบบเพื่อพิสูจน์การทำงานของแต่ละองค์ประกอบ, และทดสอบความพึงพอใจกับกลุ่มผู้ใช้งานจริง 30 คน

5.8 การสรุปผล การจัดทำรายงานวิจัย และการนำเสนอผลงาน

รวบรวมและวิเคราะห์ผลการทดลอง สรุปข้อค้นพบและข้อจำกัดของโครงการ จัดทำเล่มรายงานวิจัยฉบับสมบูรณ์ จัดทำคู่มือการใช้งานระบบ และเตรียมเอกสารเพื่อนำเสนอผลงานและส่งบทความวิจัยตีพิมพ์

6. ขอบเขตและข้อจำกัดของการวิจัย

การกำหนดขอบเขตและข้อจำกัดของโครงการวิจัย มีรายละเอียดดังนี้:

6.1 ขอบเขตของการวิจัย:

- 1) ด้านรูปแบบไฟล์ข้อมูล: รองรับไฟล์วิดีโอดิจิทัลสกุล .mp4, .mov, .mkv, .webm ความละเอียดตั้งแต่ 720p ถึง 4K UHD ที่อัตราเฟรม 24-60 เฟรมต่อวินาที
- 2) ด้านประเภทเนื้อหาวิดีโอ: ครอบคลุม 3 กลุ่มหลัก ได้แก่ วิดีโอบรรยายการเรียนการสอนและการนำเสนอทางวิชาการ, วิดีโอบันทึกการประชุม, และฟุตเทจจากกล้องวงจรปิดหรือกล้องติดหน้ารถยนต์
- 3) ด้านแบบจำลองปัญญาประดิษฐ์: ประยุกต์ใช้ SigLIP 2 NaFlex สำหรับสกัดเวกเตอร์ภาพและข้อความ และ CapRL-Qwen3VL-4B สำหรับสร้างคำบรรยายฉากและตรวจสอบความถูกต้อง
- 4) ด้านฐานข้อมูลและการสืบค้น: ใช้ LanceDB บนโครงสร้าง Apache Arrow จัดเก็บดัชนีเวกเตอร์แบบ Disk-based IVF-PQ และดัชนีข้อความ Tantivy BM25 รองรับการสืบค้นแบบไฮบริดผสานด้วย RRF

5) ด้านสถาปัตยกรรมซอฟต์แวร์: พัฒนาส่วนบริการหลังบ้านด้วย FastAPI ร่วมกับ Decord และ PyTorch และพัฒนาส่วนหน้าบ้านด้วย Next.js พร้อมแถบ Canvas Heatmap แสดงผลการสืบค้น

6) ด้านการประมวลผล: ทำงานบนเครื่องประมวลผลส่วนบุคคลทั้งหมดที่มีหน่วยความจำ VRAM 12GB โดยไม่มีการพึ่งพาบริการคลาวด์ภายนอก

6.2 ข้อจำกัดของการวิจัย:

1) ระบบทำงานบนพื้นฐานข้อมูลภาพเท่านั้น

จึงไม่ใช้สัญญาณเสียงพูดหรือข้อความตัวอักษรจากการอ่านภาพเป็นหลักฐานในการสืบค้น

2) ความแม่นยำในการค้นหาขึ้นอยู่กับความคมชัดของภาพ หากวิดีโอมีสภาพมืดจัด ภาพเบลอจากการเคลื่อนไหวรุนแรง หรือเหตุการณ์อยู่นอกมุมมองกล้อง ประสิทธิภาพอาจลดลง

3) ระบบใช้การประมวลผลแบบก้ำวหน้า ในช่วงแรกหลังนำเข้าวิดีโอทันที การค้นหาจะทำงานด้วยเวกเตอร์ภาพ SigLIP 2 เป็นหลัก จนกว่ากระบวนการสร้างคำบรรยายฉากในเบื้องหลังจะเสร็จสมบูรณ์

7. สถานที่ทำวิจัย

สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น

8. ประโยชน์ที่คาดว่าจะได้รับ

8.1

ได้ระบบซอฟต์แวร์ต้นแบบการสืบค้นและระบุช่วงเวลาในวิดีโอด้วยภาษาธรรมชาติแบบไฮบริด ที่ทำงานได้อย่างสมบูรณ์บนเครื่องประมวลผลส่วนบุคคล

8.2

ช่วยลดระยะเวลาและภาระในการค้นหาเหตุการณ์สำคัญในวิดีโอความยาวสูงของผู้ใช้งาน ได้อย่างมีนัยสำคัญ

โดยเปลี่ยนจากการเลื่อนแถบเวลาด้วยมือมาเป็นการค้นหาด้วยข้อความภาษาธรรมชาติและ
ไปยังช่วงเวลาเป้าหมายได้ทันที

8.3 ช่วยปกป้องความลับและความเป็นส่วนตัวของข้อมูลวิดีโอในองค์กร

เนื่องจากไม่มีการส่งข้อมูลภาพออกสู่คลาวด์ภายนอก

และช่วยประหยัดต้นทุนค่าบริการคลาวด์ได้อย่างเด็ดขาด

8.4

ได้พิมพ์เขียวเชิงสถาปัตยกรรมและแนวทางการประยุกต์ใช้แบบจำลองภาษาภาพรุ่นใหม่บน
ฮาร์ดแวร์ระดับทั่วไป

ซึ่งเป็นประโยชน์ต่อการศึกษาและการวิจัยทางด้านวิทยาการคอมพิวเตอร์ต่อไป

8.5

ได้ผลงานวิจัยที่มีความพร้อมสำหรับการจัดทำบทความวิจัยเพื่อส่งตีพิมพ์ในการประชุมวิชา
การระดับชาติด้านคอมพิวเตอร์

9. แผนและระยะเวลาดำเนินการ

ตารางการดำเนินงานและระยะเวลา

จากขั้นตอนในวิธีการดำเนินการวิจัยมีระยะเวลาในการดำเนินการประมาณ 12 เดือน

(ครอบคลุมปีการศึกษา 2568 ถึง 2569) ดังแสดงในตารางที่ 1:

ตารางที่ 1 แผนและระยะเวลาดำเนินการ

การดำเนินงาน	ปี 2568							ปี 2569				
	6	7	8	9	10	11	12	1	2	3	4	5
1. ศึกษาค้นคว้าทฤษฎีและงานวิจัยที่เกี่ยวข้อง	■	■										
2. ออกแบบสถาปัตยกรรมและฐานข้อมูล LanceDB		■	■									
3. พัฒนาระบบนำเข้าวิดีโอแบบก้าวหน้า			■	■								
4. นำเสนอเค้าโครงโครงการ (Proposal Defense) ★				■								
5. พัฒนาระบบสืบค้นไฮบริดและเปรียบเทียบช่วงเวลา					■	■	■					
6. พัฒนาส่วนต่อประสานผู้ใช้ Web Application							■	■	■			
7. การทดลอง ประเมินผล และการทำ User Study									■	■	■	
8. จัดทำรายงานฉบับสมบูรณ์และการสอบจบโครงการ											■	■

หมายเหตุ ปรับตามความเหมาะสม ทั้งนี้ต้องระบุช่วงที่เสนอเค้าโครงโครงการ (★

สัญลักษณ์ระบุช่วงนำเสนอเค้าโครงโครงการในเดือนกันยายน 2568)

10. งบประมาณ

หมวดวัสดุอุปกรณ์

- ค่าวัสดุสำนักงาน (กระดาษ ปากกา แฟ้มเอกสาร และอื่นๆ) 1,500 บาท
- ค่าวัสดุคอมพิวเตอร์ (แฟลชไดรฟ์ สายเชื่อมต่อ สื่อบันทึกข้อมูลสำรอง) 2,500 บาท

หมวดค่าใช้สอย

- ค่าถ่ายเอกสารและพิมพ์เอกสารทางวิชาการ 1,000 บาท
- ค่าจัดรูปเล่มเค้าโครงโครงงานและเล่มรายงานฉบับสมบูรณ์ 1,500 บาท

หมวดค่าใช้จ่ายอื่นๆ

- ค่าลงทะเบียนและเตรียมส่งบทความวิจัยในการประชุมวิชาการ 3,500 บาท

รวมงบประมาณทั้งสิ้น (หนึ่งหมื่นบาทถ้วน)

10,000 บาท

11. เอกสารอ้างอิง

รายชื่อเอกสารอ้างอิง การอ้างอิงเอกสารให้อ้างอิงตามแบบสากล (รูปแบบ APA 7th

Edition / IEEE):

Bai, S., et al. (2024). Qwen2.5-VL: Enhancing Vision-Language Models for Fine-Grained Multimodal Understanding and Localization. arXiv preprint.

Cormack, G. V., Clarke, C. L., & Buettcher, S. (2009). Reciprocal rank fusion outperforms Condorcet and individual machine learning methods for search result fusion. In Proceedings of the 32nd international ACM SIGIR conference on Research and development in information retrieval (pp. 758–759).

Gao, J., Sun, C., Yang, Z., & Nevatia, R. (2017). TALL: Temporal activity localization via language query. In Proceedings of the IEEE International Conference on Computer Vision (ICCV) (pp. 5267–5275).

- Girdhar, R., El-Nouby, A., Liu, Z., Mann, M., Rabbat, M., Singh, M., ... & Misra, I. (2023). ImageBind: One embedding space to bind them all. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) (pp. 15180–15190).
- Google DeepMind. (2025). SigLIP 2: Multilingual Vision-Language Encoders with Improved Semantic and Spatial Awareness. arXiv preprint arXiv:2502.14786.
- LanceDB Authors. (2024). LanceDB: Serverless, Developer-friendly Vector Database for Multimodal AI. LanceDB Whitepaper & Documentation.
- Lei, J., Berg, T. L., & Bansal, M. (2021). QVHighlights: Detecting moments and highlights in videos via natural language queries. In Advances in Neural Information Processing Systems (NeurIPS 2021) (Vol. 34, pp. 11846–11858).
- Lin, B., Ye, Y., Zhu, B., Cui, J., Ning, M., Jin, P., & Yuan, L. (2024). Video-LLaVA: Learning united visual representation by alignment before projection. In Findings of the Association for Computational Linguistics: EMNLP 2024 (pp. 6784–6798).
- Lin, K. Q., Zhang, P., Chen, J., Pramanick, S., Gao, X., Dai, P., & Yan, S. (2023). UniVTG: Towards unified video-language temporal grounding. In Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) (pp. 2794–2804).
- Moon, W., Hyun, S., Park, S., Park, D., & Heo, J. P. (2023). Query-dependent video representation for moment retrieval and highlight detection. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) (pp. 23023–23033).
- Ren, S., Yao, L., Li, Z., Sun, Y., & Zhu, X. (2024). TimeChat: A time-sensitive multimodal large language model for long video understanding. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) (pp. 14313–14323).
- Souček, T., & Lokoč, J. (2020). TransNet V2: An effective deep network for fast video shot boundary detection. arXiv preprint arXiv:2008.05238.
- Zhang, C. L., Wu, J., & Li, Y. (2022). ActionFormer: Localizing moments of actions with transformers. In European Conference on Computer Vision (ECCV) (pp. 492–510). Springer.
- Zhang, S., Peng, H., Fu, J., & Luo, J. (2020). Learning 2D temporal adjacent networks for moment localization with natural language. In Proceedings of the AAAI Conference on Artificial Intelligence (Vol. 34, No. 07, pp. 12870–12877).

การรับรองและตรวจสอบเค้าโครงโครงการ

ลงชื่อผู้ทำโครงการ

.....

(นาย/นางสาว)

วันที่

ลงชื่อผู้ทำโครงการ

.....

(นาย/นางสาว)

วันที่

การตรวจสอบจากอาจารย์ที่ปรึกษาโครงการ

() ตรวจสอบแล้ว เห็นชอบตามเสนอ

() อื่น ๆ

.....

.....

(ลงชื่อ)

(ผู้ช่วยศาสตราจารย์ ดร. สิลดา อินทรโสธรรัตน์)

วันที่

ภาคผนวก

ภาคผนวก ก: รายละเอียดชุดข้อมูลทดสอบมาตรฐานสากล

ชุดข้อมูลมาตรฐาน	ผู้พัฒนา / ปี	จำนวนคลิป / ความยาว	ตัวชี้วัดหลักที่ใช้ประเมิน
QVHighlights	Lei et al. (2021)	10,148 วิดีโอ (~150 ชม.)	R@1@IoU=0.5, 0.7, mIoU, HIT@1
Charades-STA	Gao et al. (2017)	9,848 ช่วงเวลา (~82 ชม.)	R@1@IoU=0.3, 0.5, 0.7, mIoU
ActivityNet Captions	Krishna et al. (2017)	20,000 วิดีโอ (~849 ชม.)	R@1@IoU=0.3, 0.5, mIoU

ภาคผนวก ข: ข้อกำหนดฮาร์ดแวร์และการใช้หน่วยความจำ VRAM

ของแต่ละแบบจำลอง

แบบจำลอง AI / ไบเบรารี	ฟังก์ชันการทำงาน	รูปแบบ Quantization / ความแม่นยำ	Peak VRAM Budget
Decord (NVDEC)	Hardware Video Decoding บน GPU	CUDA Hardware Context	~0.5 GB VRAM
SigLIP 2 NaFlex	สกัด Frame / Query Embeddings (768-dim)	FP16 / Tensor Cores	~2.2 GB VRAM
CapRL-Qwen3VL-4B	Scene Captioning & Accurate Verification	GGUF Q6_K (llama.cpp CUDA)	~4.8 GB VRAM
LanceDB Serverless	Vector Storage (IVF-PQ) & Tantivy FTS	Zero-Copy Disk Memory Mapped	~0.2 GB VRAM

ภาคผนวก ค: สถานะการพัฒนาระบบจริงในปัจจุบัน

ภาคผนวกนี้บันทึกสถานะของระบบที่ได้รับการติดตั้งและทดสอบจริงบนเครื่องคอมพิวเตอร์สำหรับการวิจัย (RTX 5070 12GB VRAM):

- โครงสร้างระบบหลัก: ระบบใช้ SigLIP 2 NaFlex เป็นแกนหลักในการสับคั่น และใช้ CapRL-Qwen3VL-4B สำหรับสร้างคำบรรยายจากและทำหน้าที่ตรวจสอบความถูกต้องผ่าน llama.cpp CUDA Worker
- การจัดการ VRAM: จัดสรรงบประมาณหน่วยความจำจริง 11.8 GB VRAM ป้องกันปัญหาหน่วยความจำไม่เพียงพอ โดยแยกโพเซสการทำงานระหว่าง FastAPI Web Server และ Inference Worker อย่างเด็ดขาด
- การประมวลผลข้อมูลแบบก้ำวหน้า: ภายหลังจากการสร้างดัชนีภาพ SigLIP 2 ในระยะแรกเสร็จสิ้น ผู้ใช้งานสามารถเริ่มทำการค้นหาวิดีโอได้ทันที จากนั้นระบบจะสร้างคำบรรยายจากด้วย CapRL ในเบื้องหลังและอัปเดตข้อมูลเมื่อเสร็จสมบูรณ์