



CS2568/หมายเลขกลุ่ม
เค้าโครงโครงงานคอมพิวเตอร์

ระบบสืบค้นและระบุช่วงเวลาในวิดีโอด้วยภาษาธรรมชาติแบบไฮบริดหลายมิติ

(Pure-Visual Video Moment Retrieval and Temporal Localization
System)

โดย

รหัสนักศึกษา นาย/นางสาว

.....

รหัสนักศึกษา นาย/นางสาว

.....

อาจารย์ที่ปรึกษา ผู้ช่วยศาสตราจารย์ ดร. สิลดา อินทรโสธรจันทร์

รายงานนี้เป็นส่วนหนึ่งของการศึกษาวิชา CP353761 สัมมนาทางวิทยาการคอมพิวเตอร์

ภาคเรียนที่ 1 ปีการศึกษา 2568

สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์

มหาวิทยาลัยขอนแก่น

(เดือน กันยายน พ.ศ. 2568)

การเสนอเค้าโครงโครงการคอมพิวเตอร์

สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น

ชื่อ นาย / นางสาว รหัสประจำตัว

Mr. / Miss

นาย / นางสาว รหัสประจำตัว

.....

Mr. / Miss

นักศึกษาระดับปริญญาตรี หลักสูตรวิทยาการคอมพิวเตอร์

อาจารย์ที่ปรึกษาโครงการ ผู้ช่วยศาสตราจารย์ ดร. สิลดา อินทรโสธรจันทร์

Project Advisor Asst. Prof. Dr. Silada Indrasothornsunt

1. ชื่อหัวข้อโครงการ

ภาษาไทย: ระบบสืบค้นและระบุช่วงเวลาในวิดีโอด้วยภาษาธรรมชาติแบบไฮบริดหลายมิติ

ภาษาอังกฤษ: Pure-Visual Video Moment Retrieval and Temporal Localization
System

2. หลักการและเหตุผล

ในยุคสารสนเทศปัจจุบัน ปริมาณข้อมูลสื่อวิดีโอความยาวสูง (Long-form Video) เติบโตขึ้นอย่างก้าวกระโดดในทุกภาคส่วน ทั้งในด้านการศึกษา เช่น วิดีโอบันทึกการเรียนการสอนและการนำเสนอทางวิชาการ (Lecture & Presentation Archives) ด้านการทำงาน เช่น วิดีโอบันทึกการประชุม (Meeting Recordings) ตลอดจนด้านความปลอดภัยและนิติวิทยาศาสตร์ เช่น ฟุตเทจจากกล้องวงจรปิดและกล้องหน้ารถยนต์ (Surveillance & Dashcam Footage) อย่างไรก็ตาม ปัญหาข้อจำกัดสำคัญที่ผู้ใช้งานต้องเผชิญคือ "ภาระในการค้นหาและระบุตำแหน่งช่วงเวลาที่เกิดเหตุการณ์เฉพาะเจาะจง" (Data Overload

and Manual Video Scrubbing) ซึ่งผู้ใช้งานต้องเสียเวลาเปิดรับชมหรือเลื่อนแถบเวลา (Time Bar) ยาวนานหลายสิบนาทีหรือหลายชั่วโมงเพื่อหาช่วงเวลาสั้น ๆ เพียงไม่กี่วินาที

ระบบสืบค้นวิดีโอแบบดั้งเดิมส่วนใหญ่ยังคงพึ่งพาเฉพาะข้อมูลกำกับภายนอก

(Metadata) เช่น ชื่อไฟล์ แท็ก หรือคำอธิบายภาพรวม

ซึ่งไม่สามารถเข้าถึงเนื้อหาเชิงลึกในระดับช่วงเวลา (Fine-grained Temporal Content)

และไม่เข้าใจคำค้นหาภาษาธรรมชาติที่ซับซ้อน เช่น

"ช่วงที่อาจารย์เริ่มอธิบายสไลด์กราฟแท่งเปรียบเทียบผลลัพธ์" หรือ

"ตอนที่มีคนสวมเสื้อสีแดงเดินเข้ามาหยิบกระเป๋าใบโตๆ" หรือ

"ฉากที่รถจักรยานยนต์เลี้ยวตัดหน้ากะทันหันก่อนถึงทางแยก"

การสืบค้นเหตุการณ์เหล่านี้จำเป็นต้องเข้าใจทั้งข้อมูลภาพ การกระทำของวัตถุ

และความสัมพันธ์เชิงเวลาอย่างลึกซึ้ง

ในช่วงปี

ค.ศ.

2024–2026

วงการปัญญาประดิษฐ์ได้พัฒนาแบบจำลองพื้นฐานด้านภาษาและภาพ (Vision-Language

Foundation Models) ที่ก้าวหน้าอย่างมาก ได้แก่ SigLIP 2 (Google DeepMind, 2025)

ซึ่งรองรับ Native Flexible Dynamic Resolution (NaFlex)

ช่วยให้รักษารายละเอียดเชิงพื้นที่ของภาพวิดีโออัตราส่วน 16:9

ได้อย่างสมบูรณ์โดยไม่ต้องตัดขอบหรือบิดเบือนภาพ ควบคู่กับโมเดลภาษาภาพขนาดใหญ่ เช่น

Qwen2.5-VL และ CapRL-Qwen3VL-4B ที่สามารถสร้างคำบรรยายจากภาพ (Dense Visual

Scene Captions) และตรวจสอบความถูกต้องของเหตุการณ์ได้

ตลอดจนฐานข้อมูลเวกเตอร์แบบฝังตัวประสิทธิภาพสูงอย่าง LanceDB

ที่ทำงานบนสถาปัตยกรรม Apache Arrow และรองรับการค้นหาแบบไฮบริด (Hybrid Search)

ทั้งเวกเตอร์ภาพและการค้นหาข้อความเต็มรูปแบบ (Full-Text Search BM25)

โครงการนี้จึงนำเสนอการวิจัยและพัฒนาแบบสืบค้นและระบุตำแหน่งช่วงเวลาในวิดีโอ

วยภาษาธรรมชาติแบบไฮบริดหลายมิติ (Pure-Visual Video Moment Retrieval and Temporal

Localization System) ที่ทำงานบนเครื่องประมวลผลส่วนบุคคล (100% Local On-Premise)

โดยไม่ต้องส่งข้อมูลออกสู่คลาวด์ภายนอก ช่วยปกป้องความเป็นส่วนตัวของข้อมูล และประหยัดค่าใช้จ่าย API โดยผสานการดึงข้อมูลเวกเตอร์ภาพและคำบรรยายจากด้วย Reciprocal Rank Fusion (RRF) ร่วมกับการเกลี่ยสัญญาณเวลา 1D Gaussian Convolution และการสกัดขอบเขตเวลาอย่างแม่นยำด้วย Soft-NMS และ Platt Calibration

3. วัตถุประสงค์ของโครงการ

- 3.1 เพื่อออกแบบและพัฒนาระบบสกัดข้อมูลวิดีโอเร่งความเร็วด้วยฮาร์ดแวร์ (Hardware-Accelerated Progressive Ingestion Pipeline) โดยใช้ Decord สำหรับถอดรหัสวิดีโอบน GPU ควบคู่กับการตัดแบ่งจากด้วย PySceneDetect เพื่อลดปริมาณเฟรมซ้ำซ้อน
- 3.2 เพื่อประยุกต์ใช้แบบจำลองภาษาภาพ (Vision-Language Models) แบบ Local On-Premise ได้แก่ SigLIP 2 และ NaFlex สำหรับการสกัดเวกเตอร์ตัวแทนของเฟรมภาพและคำค้นหา และ CapRL-Qwen3VL-4B สำหรับสร้างคำบรรยายฉากและตรวจสอบความถูกต้องเชิงลึก (Accurate Verification)
- 3.3 เพื่อพัฒนาฐานข้อมูลเวกเตอร์และระบบสืบค้นประสิทธิภาพสูง (Serverless Columnar Vector Database) โดยใช้ LanceDB บนฟอร์แมต Apache Arrow ร่วมกับดัชนี Disk-based IVF-PQ และการค้นหาข้อความเต็มรูปแบบ Tantivy FTS (BM25)
- 3.4 เพื่อพัฒนาระบบคำนวณและระบุขอบเขตช่วงเวลาเหตุการณ์ (Temporal Boundary Localization Engine) ที่ผสานคะแนนหลายมิติด้วย Reciprocal Rank Fusion (RRF), การเกลี่ยสัญญาณเวลา 1D Gaussian Temporal Convolution, การสกัดขอบเขต [t_start, t_end] ด้วย Soft-NMS, และการปรับเทียบความเชื่อมั่นด้วย Platt Calibration
- 3.5 เพื่อพัฒนาเว็บแอปพลิเคชันส่วนต่อประสานผู้ใช้แบบโต้ตอบ (Interactive Full-Stack Web Application) ด้วย Next.js 14 และ FastAPI ที่มีแถบแสดงความหนาแน่นของ relevances (1-Hz Relevance Heatmap Bar) และระบบเล่นวิดีโอแบบ Seek ไปยังช่วงเวลาเป้าหมายอัตโนมัติ

3.6 เพื่อประเมินประสิทธิภาพของระบบอย่างครอบคลุมทั้งบนชุดข้อมูลมาตรฐานสากล (QVHighlights และ Charades-STA), ชุดข้อมูลวิดีโอสถานการณ์จริง 30 ชั่วโมง, และการทดสอบกับผู้ใช้งานจริง (Task Completion Time และ SUS Score)

4. ทฤษฎีและผลงานวิจัยที่เกี่ยวข้อง

การศึกษาทฤษฎีและงานวิจัยที่เกี่ยวข้องเพื่อการพัฒนาโครงงานฉบับนี้ ได้ทำการรวบรวม วิเคราะห์ และสังเคราะห์องค์ความรู้อย่างเป็นระบบ โดยครอบคลุมทั้งวรรณกรรมวิจัยสำคัญตามกรอบการคิดวิเคราะห์ 5W1H (Who, What, Where, When, Why, How), ทฤษฎีและหลักการทางคณิตศาสตร์ที่เกี่ยวข้อง, และตารางสังเคราะห์วรรณกรรม (Synthesis Matrix) ดังมีรายละเอียดต่อไปนี้:

4.1 งานวิจัยที่เกี่ยวข้อง (การสังเคราะห์วรรณกรรมตามกรอบ 5W1H)

จากการทบทวนวรรณกรรมวิจัยสำคัญจำนวน 12 งานวิจัย สามารถจำแนกออกเป็น 4 กลุ่มหลักได้ดังนี้:

4.1.1 งานวิจัยด้านการโมเดลความสัมพันธ์เชิงเวลาและการตรวจจับด้วย

Transformer/DETR

1) โครงข่าย 2D-TAN (Zhang et al., 2020; AAAI): นำเสนอ 2D Temporal Adjacent Networks เพื่อแก้ปัญหา 1D Sliding Window ที่ขาดการมองเห็นความสัมพันธ์ของช่วงเวลาเหตุการณ์ซ้อนทับ โดยแปลงวิดีโอเป็น 2D Temporal Feature Map (แกนเริ่มต้นและแกนสิ้นสุด) และใช้ 2D Convolution จับคู่กับคำค้นหา

2) ชุดข้อมูล QVHighlights และ Moment-DETR (Lei et al., 2021; NeurIPS): เสนอเกณฑ์การประเมินช่วงเวลาแบบ Fine-grained Saliency Score รายวินาที โดยใช้โครงสร้าง DETection TRansformer ทำนายพิกัดช่วงเวลา $[t_{start}, t_{end}]$ และคะแนนความโดดเด่นตลอดคลิปไปพร้อมกัน

3) แบบจำลอง QD-DETR (Moon et al., 2023; CVPR): พัฒนา Query-Dependent DETR เพื่อแก้ปัญหาการเข้ารหัสวิดีโอแบบไม่ขึ้นกับคำค้นหา โดยใช้ Cross-Attention

ปรับแต่งการเข้ารหัสวิดีโอตั้งแต่ขั้นแรกๆ และใช้ Negative Pairs
กดคะแนนฉากที่ไม่เกี่ยวข้องลง

4) กรอบการทำงาน UniVTG (Lin et al., 2023; ICCV): รวมศูนย์ภารกิจ Moment Retrieval, Highlight Detection, และ Video Summarization เข้าด้วยกันบน Unified Transformer Backbone รองรับการถ่ายโอนความรู้ข้ามภารกิจได้อย่างมีประสิทธิภาพ

5) สถาปัตยกรรม ActionFormer (Zhang et al., 2022; ECCV): ออกแบบการตรวจจับเหตุการณ์แบบ Anchor-Free โดยใช้ Multi-scale 1D Temporal Convolution ผสานกับ Self-Attention เพื่อทำนายขอบเขตเวลาทั้งกิจกรรมสั้นและยาวได้อย่างยืดหยุ่น

4.1.2 งานวิจัยด้านแบบจำลองภาษาภาพและวิดีโอ (Vision-Language & Video Models)

6) แบบจำลอง SigLIP 2 (Google DeepMind, 2025; arXiv:2502.14786): แก้ปัญหาภาพวิดีโอ 16:9 ถูกบีบเป็นใน CLIP/SigLIP 1 ด้วยนวัตกรรม NaFlex (Native Flexible Dynamic Resolution) ที่ประมวลผลภาพตามอัตราส่วนจริง พร้อมใช้ Pairwise Sigmoid Loss, Masked Prediction, และ Self-Distillation ทำให้เข้าใจตำแหน่งเชิงพื้นที่ (Spatial Awareness) ได้เหนือกว่าเดิมอย่างมาก

7) Qwen2.5-VL / CapRL-Qwen3VL-4B (Qwen Team / InternLM, 2024–2025): โมเดลภาษาภาพขนาดใหญ่สำหรับสร้าง Dense Visual Scene Captions และทำหน้าที่ตรวจสอบเหตุการณ์เชิงลึก (Accurate Verification) โดยส่งเฟรมภาพจริงพร้อม Timestamp เข้าไปให้โมเดลประเมิน

8) แบบจำลอง TimeChat (Ren et al., 2024; CVPR): แก้ปัญหา Time-Blindness ของ LLM โดยใช้ Time-Aware Frame Encoder ร่วมกับ Time Binding Tokens เพื่อผูกมิติเวลาเข้ากับคำตอบของโมเดล

9) แบบจำลอง Video-LLaVA (Lin et al., 2024; EMNLP): ผสานพื้นที่ Representation ของภาพนิ่งและวิดีโอให้อยู่ในระนาบเดียวกัน ช่วยให้โมเดลเข้าใจความสัมพันธ์เชิงบริบทได้สมบูรณ์ยิ่งขึ้น

4.1.3

งานวิจัยด้านการตรวจสอบลำดับการกระทำเชิงภาพและการตรวจจับรอยต่อฉาก

- 10) สถาปัตยกรรม Two-Stage Retrieval: แยกการค้นหาลำดับการกระทำเชิงภาพเร็วสูง (Fast Stage ด้วย Vector & BM25) ออกจากการตรวจสอบเชิงลึกที่มีต้นทุนสูง (Accurate Stage ด้วย VLM) เพื่อควบคุมเวลาและทรัพยากร
- 11) ImageBind (Girdhar et al., 2023; CVPR): พิสูจน์แนวคิดการใช้ภาพเป็นแกนกลางในการเชื่อมโยงข้อมูลหลายโมดัลลิตี้ (Image-Centric Joint Latent Space) เป็นรากฐานสำคัญของการสืบค้นแบบไฮบริด
- 12) TransNet V2 (Souček & Lokoč, 2020): สถาปัตยกรรม Dilated 3D CNN ตรวจจับรอยต่อฉาก (Shot Transitions) ความเร็วสูงกว่า 500 fps เพื่อตัดแบ่งวิดีโอและลดเฟรมซ้ำซ้อนลงกว่า 75%

ตารางที่ 4.1 สรุปการวิเคราะห์งานวิจัยที่เกี่ยวข้องด้วยกรอบ 5W1H

งานวิจัย	ผู้พัฒนา	ปี	สาระสำคัญที่พัฒนา	ปัญหาที่แก้ไข	วิธีการหลัก
2D-TAN	Zhang et al.	2020	2D Temporal Adjacent Networks	1D Window ขาดความสัมพันธ์ข้ามเวลา	2D Convolution บน Feature Map
Moment-DETR	Lei et al.	2021	Joint Moment & Saliency Grounding	ขาดเกณฑ์ประเมินคะแนนระดับวินาที	Transformer Direct Set Prediction
QD-DETR	Moon et al.	2023	Query-Dependent Video DETR	ฉากที่ไม่เกี่ยวข้องได้คะแนนสูงเกินจริง	Query Cross-Attention & Negative Loss

งานวิจัย	ผู้พัฒนา	ปี	สาระสำคัญที่พัฒนา	ปัญหาที่แก้ไข	วิธีการหลัก
UniVTG	Lin et al.	2023	Unified Temporal Grounding	การแยกพัฒนาแต่ละภารกิจย่อยในอดีต	Unified Transformer Backbone
ActionFormer	Zhang et al.	2022	Anchor-free 1D Temporal Grounding	กรอบเวลาแบบ Anchor ขาดความยืดหยุ่น	Multi-scale 1D Temporal Pyramid
SigLIP 2	DeepMind	2025	NaFlex Vision-Language Model	ภาพ 16:9 ถูกยืดและสูญเสียมิติพื้นที่	NaFlex Dynamic Res & Sigmoid Loss
Qwen2.5-VL	Qwen Team	2024	Dense Caption + Verification	VLM ทั่วไปประมวลผลช้าเกินไป	Sequential Top-3 Candidates Verify
TimeChat	Ren et al.	2024	Time-Sensitive Video-LLM	LLM ขาดความเข้าใจลำดับมิติเวลา	Time Binding Tokens & Frame Encoder
Video-LLaVA	Lin et al.	2024	Unified Image-Video Representation	การแยก Representation ภาพและวิดีโอ	Joint Representation Alignment Layer
Pure-Visual	โครงการนี้	2026	Dual-Channel Hybrid Retrieval	การพึ่งพาเสียงหรือ Cloud API ราคาแพง	Frame SigLIP 2 + Scene BM25 + RRF
ImageBind	Girdhar et al.	2023	One Embedding for 6 Modalities	การผสมผสานหลายมิติขาดคู่ข้อมูลจับคู่	Image-Centric Joint Binding Space
TransNet V2	Souček et al.	2020	Fast Shot Boundary Detection	การประมวลผลทุกเฟรมทำให้ระบบช้า	Dilated 3D Convolutional Network

4.2 ทฤษฎีและหลักการทางคณิตศาสตร์ที่เกี่ยวข้อง

4.2.1 ทฤษฎี Vision-Language Joint Latent Space และ NaFlex Resolution: แบบจำลองแปลงเฟรมภาพ f_t และคำค้นหาข้อความ Q ให้อยู่ในปริภูมิเวกเตอร์เดียวกันขนาด $d = 768$ มิติ โดยคำนวณความคล้ายคลึงด้วย Cosine Similarity:

$$\text{Cosine_Similarity}(f_t, Q) = (v_t \cdot u_q) / (\|v_t\| \times \|u_q\|)$$

โดยที่ v_t คือเวกเตอร์แทนภาพจาก NaFlex Vision Encoder และ u_q คือเวกเตอร์แทนข้อความจาก Text Encoder กลไก NaFlex ช่วยให้โมเดลรองรับภาพอัตราส่วน 16:9 ได้โดยตรงโดยไม่สูญเสียความละเอียดเชิงพื้นที่

4.2.2 ทฤษฎี Pairwise Sigmoid Loss: SigLIP 2 ใช้ฟังก์ชันการสูญเสียแบบ Sigmoid แทน Softmax ดั้งเดิม ช่วยลดการพึ่งพา Global Batch Size และทำให้เวกเตอร์มีความเสถียรสูงขึ้น:

$$L_{\text{SigLIP}} = - \sum_{i=1}^N \sum_{j=1}^N [y_{ij} \cdot \log \sigma(t \cdot u_i \cdot v_j + b) + (1 - y_{ij}) \cdot \log(1 - \sigma(t \cdot u_i \cdot v_j + b))]$$

โดย $y_{ij} = 1$ สำหรับคู่ที่ตรงกัน (Positive Pair) และ $y_{ij} = 0$ สำหรับคู่ตรงข้าม (Negative Pair), σ คือ Sigmoid Activation, t คือ Temperature, และ b คือ Learnable Bias

4.2.3 ทฤษฎีการรวมผลลัพธ์ด้วย Reciprocal Rank Fusion (RRF): ผสานผลลัพธ์จากสายเวกเตอร์ภาพ (Visual Similarity) และสายคำบรรยายฉาก (Caption BM25) ที่มีมาตรวัดต่างกันโดยไม่ต้อง Normalize สเกลคะแนน:

$$\text{RRF}(d) = \sum_{m \in \{\text{Visual}, \text{Caption}\}} [w_m / (k + r_m(d))]$$

โดย $r_m(d)$ คืออันดับของข้อมูลในแต่ละโมดัลลิตี้ กำหนด $k = 60$ เพื่อป้องกันอันดับแรกมีน้ำหนักสูงเกินไป และ w_m คือค่าน้ำหนัก (Visual = 0.80, Caption = 0.20)

4.2.4 ทฤษฎี Multi-Scale Temporal Proposals และ 1D Gaussian Convolution: สร้างช่วงเวลาผู้สมัครที่ความยาวต่าง ๆ (2, 4, 8, 16, 32 วินาที) โดยนำคะแนน $S(t)$ มาผ่านตัวกรอง Gaussian Filter: $S_{\text{smooth}}(t) = S(t) * G_{\sigma}$ เพื่อลดสัญญาณรบกวน

จากนั้นขยายขอบเขตจากจุด Local Peak จนคะแนนลดต่ำกว่า 60% ของจุดสูงสุด และใช้ Gaussian Soft-NMS (IoU = 0.5) เพื่อตัดช่วงซ้ำซ้อน

4.2.5 ทฤษฎีการปรับเทียบความเชื่อมั่น (Platt Calibration) และ No-Match Gate: ใช้ฟังก์ชัน Logistic Sigmoid แปลงคะแนนดิบเป็นค่าความน่าจะเป็นเชิงสถิติ $P(Y=1|S) = 1 / (1 + \exp(A \cdot S + B))$ เพื่อตัดช่วงเวลาที่ไม่เกี่ยวข้อง (No-match queries) ออกอย่างแม่นยำ

4.2.6 ทฤษฎีการจัดเก็บและสร้างดัชนีเวกเตอร์แบบ Disk-based IVF-PQ: LanceDB ใช้สถาปัตยกรรม Columnar บน Apache Arrow ร่วมกับดัชนี Inverted File with Product Quantization (IVF-PQ) แบ่งเวกเตอร์ 768 มิติออกเป็นคลัสเตอร์และบีบอัดแต่ละส่วน ช่วยประหยัดหน่วยความจำได้ 8–16 เท่า และสืบค้นได้เร็วกว่า 5 มิลลิวินาที

ตารางที่ 4.2 ตารางสังเคราะห์วรรณกรรม (Synthesis Matrix)

เปรียบเทียบสถาปัตยกรรมและมิติข้อมูล

แนวทาง / งานวิจัย	มิติข้อมูล	สถาปัตยกรรมหลัก	จุดเด่นสำคัญ	ข้อจำกัดและช่องว่างวิจัย
Proposal-based (2D-TAN)	Visual Only (2D CNN)	Sliding Window & 2D Temporal Feature Map	เข้าใจความสัมพันธ์ของช่วงเวลาซ้อนทับได้ดี	ไม่รองรับ Open-Vocabulary คำนวนซ้ำบนวิดีโอยาว
DETR-based (Moment-DETR)	Visual + Text	Transformer Encoder-Decoder Set Prediction	ทำนายช่วงเวลาและ Highlight Score พร้อมกัน	ต้อง Fine-tune บนชุดข้อมูลปิด กิน VRAM สูง
Unified Grounding (UniVTG)	Visual + Text	Multi-scale 1D Temporal Convolution	สกัดเหตุการณ์สั้นและยาวได้อย่างยืดหยุ่น	ยังขาดระบบดัชนีเวกเตอร์ที่รองรับคลังวิดีโอใหญ่

แนวทาง / งานวิจัย	มิติข้อมูล ล	สถาปัตยกรรมหลัก	จุดเด่นสำคัญ	ข้อจำกัดและช่องว่างวิจัย
Video-LLM (TimeChat)	Visual + Text	Large Language Model & Time Tokens	เข้าใจการกระทำซับซ้อนและตอบคำถามเหตุผลได้	กินทรัพยากรสูง ประมวลผลช้า เหมาะกับ Re-rank
Two-Stage (SeViLA)	Multi-modal Binding	Localizer-Filter + Answerer VLM	ประหยัด Token ในงาน Video QA	ไม่มี Vector DB ผังตัวสำหรับค้นหาพื้นที่
Proposed Pure-Visual (โครงงานนี้)	Visual Vector + Dense Caption	SigLIP 2 NaFlex + Qwen + LanceDB	รักษา Aspect Ratio, รองรับหลาย Moments, Local VRAM $\leq 12\text{GB}$	ต้องทำดัชนีล่วงหน้า และขึ้นกับความคมชัดของภาพ

4.3 บทวิเคราะห์สังเคราะห์วรรณกรรม (Literature Review Synthesis): จากการทบทวนวรรณกรรมพบประเด็นสำคัญ 3 ประการ ได้แก่ (1) การผสานสัญญาณสองช่องทาง: Frame Embeddings ครอบคลุมเส้นเวลา ส่วน Scene Captions ช่วยจับการกระทำเชิงสัมพันธ์ (2) ความสำคัญของอัตราส่วนภาพ: เทคโนโลยี NaFlex ช่วยแก้ปัญหาภาพบิดเบือนในวิดีโอ 16:9 และ (3) ความสมดุลด้านความเร็ว: การออกแบบสองระยะ (Fast Stage ระดับมิลลิวินาที และ Accurate Stage สำหรับตรวจทานเชิงลึก) ช่วยให้ตอบสนองผู้ใช้ได้ทันทีโดยไม่ติดขัด

5. วิธีดำเนินการวิจัย

โครงงานนี้ได้กำหนดขั้นตอนและระเบียบวิธีดำเนินการวิจัยออกเป็น 8 ขั้นตอนหลัก เพื่อให้การพัฒนาระบบเป็นไปอย่างมีประสิทธิภาพและบรรลุวัตถุประสงค์ที่ตั้งไว้ ดังนี้:

5.1 การศึกษาค้นคว้าทฤษฎีและเทคโนโลยีที่เกี่ยวข้อง

ศึกษาทฤษฎีด้าน Vision-Language Foundation Models, Video Moment Retrieval, Vector Database, และ Temporal Boundary Localization ตลอดจนศึกษาสถาปัตยกรรม SigLIP 2, Qwen2.5-VL, Decord, LanceDB, และ Next.js 14

5.2 การออกแบบสถาปัตยกรรมระบบโดยรวม (System Architecture Design)

ออกแบบสถาปัตยกรรมแบบ Progressive Dual-Stream ประกอบด้วย Ingestion Pipeline สำหรับนำเข้าและสร้างดัชนีวิดีโอ, Storage Layer บน LanceDB, Retrieval Engine ผสาน RRF และ Gaussian Smoothing, และ User Interface Dashboard

5.3 การออกแบบโครงสร้างฐานข้อมูลเวกเตอร์ LanceDB (Database Schema Design)

ออกแบบตารางข้อมูล Apache Arrow ประกอบด้วย videos (จัดเก็บข้อมูลไฟล์), video_frames_v2 (จัดเก็บเวกเตอร์ 768 มิติของเฟรมภาพ), scenes_v2 (จัดเก็บคำบรรยายฉากและสถานะ caption), index_metadata (ตรวจสอบความเข้ากันได้ของโมเดล), และ search_logs

5.4 การพัฒนาระบบนำเข้าและประมวลผลวิดีโอแบบก้าวหน้า (Progressive Video Ingestion Pipeline)

พัฒนาโมดูลถอดรหัสวิดีโอด้วย Decord NVDEC GPU Acceleration, โมดูลตรวจจ็อบรอยต่อฉากด้วย PySceneDetect, และโมดูลสกัดเวกเตอร์ SigLIP 2 ทันทีใน Phase 1 เพื่อเปิดให้ค้นหาได้รวดเร็ว ก่อนส่งออกไปสร้างคำบรรยายด้วย VLM ใน Background Worker

5.5 การพัฒนาระบบสืบค้นและระบุตำแหน่งเวลาแบบไฮบริด (Hybrid Retrieval & Boundary Engine)

พัฒนาระบบค้นหาคู่ขนานระหว่าง Dense Vector Search (Cosine Similarity) และ Sparse Text Search (BM25 บน Scene Captions), ผสานคะแนนด้วย RRF,

เกลี่ยสัญญาณด้วย 1D Gaussian Convolution, สกัดช่วงเวลา [t_start, t_end] ด้วย Multi-scale Proposals และ Soft-NMS, และปรับเทียบความเชื่อมั่นด้วย Platt Calibration

5.6 การพัฒนาเว็บแอปพลิเคชันส่วนต่อประสานผู้ใช้ (Interactive Full-Stack Web Application)

พัฒนาเว็บแอปพลิเคชันด้วย Next.js 14 (App Router) และ FastAPI
รองรับการอัปเดตวิดีโอ, แถบแสดงความหนาแน่นความเกี่ยวข้อง Dynamic Relevance
Density Heatmap (1-Hz Canvas Bar), ระบบเล่นวิดีโอ Auto-Seek ไปยังช่วงเวลาทีพบ,
และแผง Telemetry ดูการใช้ GPU/VRAM

5.7 การทดลองและประเมินประสิทธิภาพของระบบ (Comprehensive Evaluation & Ablation Study)

ทดสอบประสิทธิภาพบนชุดข้อมูลมาตรฐาน QVHighlights และ Charades-STA, ทดสอบบนวิดีโอสถานการณ์จริง 30 ชั่วโมง, ทำการทดลอง Ablation Study 5 รูปแบบเพื่อพิสูจน์การทำงานของแต่ละองค์ประกอบ, และทดสอบความพึงพอใจกับผู้ใช้งานจริง 30 คน (SUS Score)

5.8 การสรุปผล การจัดทำรายงานวิจัย และการนำเสนอผลงาน

รวบรวมและวิเคราะห์ผลการทดลอง	สรุปข้อค้นพบและข้อจำกัดของโครงการ
จัดทำเล่มรายงานวิจัยฉบับสมบูรณ์	จัดทำคู่มือการใช้งานระบบ
และเตรียมเอกสารเพื่อนำเสนอผลงานและส่งบทความวิจัยตีพิมพ์	

6. ขอบเขตและข้อจำกัดของการวิจัย

การกำหนดขอบเขตและข้อจำกัดของโครงการวิจัย มีรายละเอียดดังนี้:

6.1 ขอบเขตของการวิจัย (สิ่งที่สามารถทำได้และทำได้ดีที่สุด):

- 1) ด้านรูปแบบไฟล์ข้อมูล: รองรับไฟล์วิดีโอดิจิทัลสกุล .mp4, .mov, .mkv, .webm
ความละเอียดตั้งแต่ 720p (HD) ถึง 2160p (4K UHD) ที่อัตราเฟรม 24-60 fps

- 2) ด้านประเภทเนื้อหาวิดีโอ: ครอบคลุม 3 โดเมนหลัก ได้แก่ วิดีโอบรรยายการเรียนการสอน (Lectures/Presentations), วิดีโอบันทึกการประชุม (Meeting Archives), และฟุตเทจกล้องวงจรปิด/กล้องหน้ารถยนต์ (Surveillance/Dashcam)
- 3) ด้านแบบจำลองปัญญาประดิษฐ์: ประยุกต์ใช้ google/siglip2-base-patch16-naflex (768 มิติ) สำหรับสกัดเวกเตอร์ภาพและข้อความ และ CapRL-Qwen3VL-4B (Quantized Q6_K) สำหรับสร้างคำบรรยายฉากและตรวจสอบความถูกต้อง
- 4) ด้านฐานข้อมูลและการสืบค้น: ใช้ LanceDB Serverless Columnar บน Apache Arrow จัดเก็บดัชนีเวกเตอร์แบบ Disk-based IVF-PQ และดัชนีข้อความ Tantivy FTS (BM25) รองรับการสืบค้นแบบไฮบริดผสมผสานด้วย RRF
- 5) ด้านสถาปัตยกรรมซอฟต์แวร์: พัฒนา Backend ด้วย FastAPI + Decord + PyTorch และ Frontend ด้วย Next.js 14 + Tailwind CSS พร้อม Canvas Heatmap แสดงผลการสืบค้น
- 6) ด้านการประมวลผล: ทำงานแบบ 100% Local On-Premise บนเครื่องที่มีการ์ดจอ NVIDIA VRAM 12GB (เช่น RTX 5070) โดยไม่มีค่าใช้จ่าย API ภายนอก

6.2 ข้อจำกัดของการวิจัย (สิ่งที่ไม่สามารถทำได้):

- 1) ระบบทำงานบนพื้นฐาน Pure-Visual เท่านั้น จึงไม่ใช้สัญญาณเสียงพูด (Audio Transcription) หรือข้อความตัวอักษร OCR บนภาพเป็นหลักฐานในการสืบค้น
- 2) ความแม่นยำในการค้นหาขึ้นอยู่กับความคมชัดของภาพ หากวิดีโอมีสภาพมืดจัด ภาพเบลอจากการเคลื่อนไหวรุนแรง หรือเหตุการณ์อยู่นอกมุมมองกล้อง ประสิทธิภาพอาจลดลง
- 3) ระบบใช้การประมวลผลแบบ Progressive Ingestion ในช่วงแรกหลังอัปโหลดวิดีโอทันที การค้นหาจะทำงานด้วยเวกเตอร์ภาพ SigLIP 2 เป็นหลัก จนกว่ากระบวนการสร้างคำบรรยายฉากใน Background จะเสร็จสมบูรณ์

7. สถานที่ทำวิจัย

สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น

8. ประโยชน์ที่คาดว่าจะได้รับ

8.1

ได้ระบบซอฟต์แวร์ต้นแบบการสืบค้นและระบุช่วงเวลาในวิดีโอด้วยภาษาธรรมชาติแบบไฮบ

ริด (Pure-Visual Video Moment Retrieval System)

ที่ทำงานได้อย่างสมบูรณ์บนเครื่องเฉพาะที่ (Local On-Premise 100%)

8.2

ช่วยลดระยะเวลาและภาระในการค้นหาเหตุการณ์สำคัญในวิดีโอความยาวสูงของผู้ใช้งานได้อย่างมีนัยสำคัญ โดยเปลี่ยนจากการเลื่อนแถบเวลาด้วยมือ (Manual Scrubbing) มาเป็นการค้นหาด้วยข้อความภาษาธรรมชาติและกระโดดไปยังช่วงเวลาเป้าหมายได้ในเสี้ยววินาที

8.3 ช่วยปกป้องความลับและความเป็นส่วนตัวของข้อมูลวิดีโอในองค์กร (Complete Data Privacy)

เนื่องจากไม่มีการส่งข้อมูลภาพออกสู่คลาวด์ภายนอก และช่วยประหยัดต้นทุนค่าบริการ API รายเดือนได้อย่างเด็ดขาด

8.4 ได้พิมพ์เขียวเชิงสถาปัตยกรรม (Architectural Blueprint)

และแนวทางการประยุกต์ใช้โมเดล Vision-Language รุ่นใหม่ (SigLIP 2 NaFlex ร่วมกับ VLM) บนฮาร์ดแวร์ระดับผู้บริโภค (Consumer GPU)

ซึ่งเป็นประโยชน์ต่อการศึกษาและการวิจัยทางด้านวิทยาการคอมพิวเตอร์ต่อไป

8.5

ได้ผลงานวิจัยที่มีความพร้อมสำหรับการจัดทำบทความวิจัยเพื่อส่งตีพิมพ์ในการประชุมวิชาการระดับชาติด้านคอมพิวเตอร์ (เช่น JCSSE หรือ ECTI-CON)

9. แผนและระยะเวลาดำเนินการ

ตารางการดำเนินงานและระยะเวลา

จากขั้นตอนในวิธีการดำเนินการวิจัยมีระยะเวลาในการดำเนินการประมาณ 12 เดือน
(ครอบคลุมปีการศึกษา 2568 ถึง 2569) ดังแสดงในตารางที่ 1:

ตารางที่ 1 แผนและระยะเวลาดำเนินการ

การดำเนินงาน	ปี 2568							ปี 2569				
	6	7	8	9	10	11	12	1	2	3	4	5
1. ศึกษาค้นคว้าทฤษฎีและงานวิจัยที่เกี่ยวข้อง												
2. ออกแบบสถาปัตยกรรมและฐานข้อมูล LanceDB												
3. พัฒนาระบบนำเข้าวิดีโอ (Progressive Ingestion)												
4. นำเสนอเค้าโครงโครงการ (Proposal Defense) ★												
5. พัฒนาระบบสืบค้นไฮบริดและ Temporal Smoothing												
6. พัฒนาส่วนต่อประสานผู้ใช้ Web Application												
7. การทดลอง ประเมินผล และการทำ User Study												
8. จัดทำรายงานฉบับสมบูรณ์และการสอบจบโครงการ												

หมายเหตุ ปรับตามความเหมาะสม ทั้งนี้ต้องระบุช่วงที่เสนอเค้าโครงโครงการ (★)

สัญลักษณ์ระบุช่วงนำเสนอเค้าโครงโครงการในเดือนกันยายน 2568)

10. งบประมาณ

หมวดวัสดุอุปกรณ์

- ค่าวัสดุสำนักงาน (กระดาษ ปากกา แฟ้มเอกสาร และอื่นๆ) 1,500 บาท
- ค่าวัสดุคอมพิวเตอร์ (แฟลชไดรฟ์, สายเชื่อมต่อ, สื่อบันทึกข้อมูลสำรอง) 2,500 บาท

หมวดค่าใช้สอย

- ค่าถ่ายเอกสารและพิมพ์เอกสารทางวิชาการ 1,000 บาท
- ค่าจัดรูปเล่มเค้าโครงโครงการและเล่มรายงานฉบับสมบูรณ์ 1,500 บาท

หมวดค่าใช้จ่ายอื่นๆ

- ค่าลงทะเบียนและเตรียมส่งบทความวิจัยในการประชุมวิชาการ 3,500 บาท

รวมงบประมาณทั้งสิ้น (หนึ่งหมื่นบาทถ้วน)

10,000 บาท

11. เอกสารอ้างอิง

รายชื่อเอกสารอ้างอิง การอ้างอิงเอกสารให้อ้างอิงตามแบบสากล (รูปแบบ APA 7th

Edition / IEEE):

Bai, S., et al. (2024). Qwen2.5-VL: Enhancing Vision-Language Models for Fine-Grained Multimodal Understanding and Localization. arXiv preprint.

Cormack, G. V., Clarke, C. L., & Buettcher, S. (2009). Reciprocal rank fusion outperforms Condorcet and individual machine learning methods for search result fusion. In Proceedings of the 32nd international ACM SIGIR conference on Research and development in information retrieval (pp. 758–759).

Gao, J., Sun, C., Yang, Z., & Nevatia, R. (2017). TALL: Temporal activity localization via language query. In Proceedings of the IEEE International Conference on Computer Vision (ICCV) (pp. 5267–5275).

- Girdhar, R., El-Nouby, A., Liu, Z., Mann, M., Rabbat, M., Singh, M., ... & Misra, I. (2023). ImageBind: One embedding space to bind them all. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) (pp. 15180–15190).
- Google DeepMind. (2025). SigLIP 2: Multilingual Vision-Language Encoders with Improved Semantic and Spatial Awareness. arXiv preprint arXiv:2502.14786.
- LanceDB Authors. (2024). LanceDB: Serverless, Developer-friendly Vector Database for Multimodal AI. LanceDB Whitepaper & Documentation.
- Lei, J., Berg, T. L., & Bansal, M. (2021). QVHighlights: Detecting moments and highlights in videos via natural language queries. In Advances in Neural Information Processing Systems (NeurIPS 2021) (Vol. 34, pp. 11846–11858).
- Lin, B., Ye, Y., Zhu, B., Cui, J., Ning, M., Jin, P., & Yuan, L. (2024). Video-LLaVA: Learning united visual representation by alignment before projection. In Findings of the Association for Computational Linguistics: EMNLP 2024 (pp. 6784–6798).
- Lin, K. Q., Zhang, P., Chen, J., Pramanick, S., Gao, X., Dai, P., & Yan, S. (2023). UniVTG: Towards unified video-language temporal grounding. In Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) (pp. 2794–2804).
- Moon, W., Hyun, S., Park, S., Park, D., & Heo, J. P. (2023). Query-dependent video representation for moment retrieval and highlight detection. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) (pp. 23023–23033).
- Ren, S., Yao, L., Li, Z., Sun, Y., & Zhu, X. (2024). TimeChat: A time-sensitive multimodal large language model for long video understanding. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) (pp. 14313–14323).
- Souček, T., & Lokoč, J. (2020). TransNet V2: An effective deep network for fast video shot boundary detection. arXiv preprint arXiv:2008.05238.
- Zhang, C. L., Wu, J., & Li, Y. (2022). ActionFormer: Localizing moments of actions with transformers. In European Conference on Computer Vision (ECCV) (pp. 492–510). Springer.

Zhang, S., Peng, H., Fu, J., & Luo, J. (2020). Learning 2D temporal adjacent networks for moment localization with natural language. In Proceedings of the AAAI Conference on Artificial Intelligence (Vol. 34, No. 07, pp. 12870–12877).

การรับรองและตรวจสอบเค้าโครงโครงการ

ลงชื่อผู้ทำโครงการ

.....

(นาย/นางสาว

.....)

วันที่

ลงชื่อผู้ทำโครงการ

.....

(นาย/นางสาว

.....)

วันที่

การตรวจสอบจากอาจารย์ที่ปรึกษาโครงการ

() ตรวจสอบแล้ว เห็นชอบตามเสนอ

() อื่น ๆ

.....

.....

(ลงชื่อ)

(ผู้ช่วยศาสตราจารย์ ดร. สิลดา อินทรโสธรจันทร์)

วันที่

ภาคผนวก (Appendices)

ภาคผนวก ก: รายละเอียดชุดข้อมูลทดสอบมาตรฐานสากล (Benchmark Datasets)

ชุดข้อมูลมาตรฐาน	ผู้พัฒนา / ปี	จำนวนคลิป / ความยาว	ตัวชี้วัดหลักที่ใช้ประเมิน
QVHighlights	Lei et al. (2021)	10,148 วิดีโอ (~150 ชม.)	R@1@IoU=0.5, 0.7, mIoU, HIT@1
Charades-STA	Gao et al. (2017)	9,848 ช่วงเวลา (~82 ชม.)	R@1@IoU=0.3, 0.5, 0.7, mIoU
ActivityNet Captions	Krishna et al. (2017)	20,000 วิดีโอ (~849 ชม.)	R@1@IoU=0.3, 0.5, mIoU

ภาคผนวก ข: ข้อกำหนดฮาร์ดแวร์และการใช้หน่วยความจำ VRAM

ของแต่ละแบบจำลอง

แบบจำลอง AI / ไบรารี	ฟังก์ชันการทำงาน	รูปแบบ Quantization / ความแม่นยำ	Peak VRAM Budget
Decord (NVDEC)	Hardware Video Decoding บน GPU	CUDA Hardware Context	~0.5 GB VRAM
SigLIP 2 NaFlex	สกัด Frame / Query Embeddings (768-dim)	FP16 / Tensor Cores	~2.2 GB VRAM
CapRL-Qwen3VL-4B	Scene Captioning & Accurate Verification	GGUF Q6_K (llama.cpp CUDA)	~4.8 GB VRAM
LanceDB Serverless	Vector Storage (IVF-PQ) & Tantivy FTS	Zero-Copy Disk Memory Mapped	~0.2 GB VRAM

ภาคผนวก ค: สถานะการพัฒนาระบบจริง (Current Implementation Status @ commit 6de9468)

ภาคผนวกนี้บันทึกสถานะของระบบที่ได้รับการติดตั้งและทดสอบจริงบนเครื่องคอมพิวเตอร์สำหรับการวิจัย (RTX 5070 12GB VRAM):

- Production Stack: ระบบใช้ SigLIP 2 NaFlex เป็น Retrieval Backbone หลัก และใช้ CapRL-Qwen3VL-4B Q6_K สำหรับสร้าง Structured Scene Captions และทำหน้าที่เป็น Accurate Verifier ผ่าน llama.cpp CUDA Worker
- การจัดการ VRAM: จัดสรรงบประมาณหน่วยความจำจริง 11.8 GB VRAM ป้องกัน Out-of-Memory โดยแยก Process ระหว่าง FastAPI Web Server และ Inference Worker อย่างเด็ดขาด
- วงจรชีวิตข้อมูลแบบก้าวหน้า (Progressive Lifecycle): หลังสร้างดัชนีภาพ SigLIP 2 เสร็จสิ้น (Phase 1) ผู้ใช้สามารถเริ่มค้นหาวิดีโอได้ทันที จากนั้นระบบจะสร้างคำบรรยายจากด้วย CapRL Q6 ใน Background และอัปเดตแบบ Atomic เมื่อเสร็จสมบูรณ์